



Sistema de Predição de Obesidade

Lais Costa Santos Teixeira – RM 365830

Curso: Data Analytics

Fevereiro de 2026

1. Introdução	2
2. Base de Dados	3
3. Metodologia	3
3.1. Tratamento dos Dados e Análise Exploratória (EDA)	3
3.2. Modelagem e Pipeline de Machine Learning.....	4
3.3. Deploy e Aplicação Preditiva (Streamlit)	5
4. Dashboard Analítico	5
5. Estrutura do Repositório	6
6. Entregáveis	7
7. Conclusão	7

1. Introdução

A obesidade é uma condição médica crescente que impacta a saúde de pacientes de todas as idades. Detectar precocemente pessoas com maior risco pode melhorar intervenções médicas.

O objetivo do projeto é desenvolver um modelo de Machine Learning para auxiliar médicos a prever o nível de obesidade.

2. Base de Dados

A base utilizada foi obesity.csv, contendo variáveis relacionadas a hábitos alimentares, estilo de vida e características físicas.

Dicionário de dados:

Gender: gênero do paciente

Age: idade

Height: altura (m)

Weight: peso (kg)

family_history: histórico familiar de excesso de peso

FAVC: consumo frequente de alimentos calóricos

FCVC: consumo de vegetais nas refeições

NCP: número de refeições principais por dia

CAEC: consumo de alimentos entre refeições

SMOKE: hábito de fumar

CH2O: ingestão diária de água

SCC: monitoramento de calorias ingeridas

FAF: frequência de atividade física

TUE: tempo de uso de dispositivos tecnológicos

CALC: consumo de álcool

MTRANS: meio de transporte utilizado

Obesity: variável alvo (nível de obesidade)

3. Metodologia

3.1. Tratamento dos Dados e Análise Exploratória (EDA)

Importação e Carregamento: Utilização das bibliotecas pandas, numpy, matplotlib, seaborn e scikit-learn.

Qualidade dos Dados:

Na etapa inicial, os dados foram carregados e avaliados quanto à qualidade.

- Foram identificados registros duplicados, mas mantidos por representarem possíveis pacientes distintos com respostas semelhantes.
- Não foram encontrados valores nulos ou inconsistências nas variáveis.
- A distribuição das variáveis numéricas mostrou valores dentro da realidade, sem outliers relevantes.
- A variável alvo (**Obesity**) apresentou distribuição equilibrada entre as classes, não sendo necessário aplicar técnicas de balanceamento.

A análise exploratória permitiu compreender o comportamento das variáveis e identificar padrões importantes para a modelagem.

3.2. Modelagem e Pipeline de Machine Learning

Após a verificação da qualidade dos dados, foi desenvolvida uma pipeline em Python no VS Code para estruturar o processo de modelagem.

Principais etapas da pipeline:

Importação e preparação dos dados: leitura da base, checagem de nulos e duplicados.

Separação de variáveis: definição de X (features) e y (target).

Codificação de variáveis categóricas: aplicação de One-Hot Encoding.

Normalização: uso de StandardScaler para padronizar variáveis numéricas.

Divisão treino/teste: 80% para treino e 20% para teste.

Treinamento de modelos: foram avaliados três modelos— Random Forest, SVM e KNN.

Seleção do melhor modelo: escolha baseada na maior acurácia obtida no conjunto de teste.

Avaliação final: matriz de confusão e relatório de classificação para análise de desempenho.

Persistência do modelo: salvamento do modelo, scaler e colunas em arquivos .pkl para uso posterior no deploy.

Além do treinamento e avaliação, o pipeline também realizou a persistência do modelo.

Foram gerados arquivos no formato .pkl (Pickle) contendo:

model.pkl → o modelo de Machine Learning selecionado como melhor.

scaler.pkl → o objeto responsável pela normalização dos dados.

colunas.pkl → a lista de colunas utilizadas no treinamento, garantindo consistência na aplicação.

Esses arquivos permitem que o modelo seja carregado posteriormente sem necessidade de reprocessar ou retreinar, viabilizando o deploy na aplicação Streamlit.

```
PS C:\Users\laisc\OneDrive\Cursos\FIAP_Pos - Data Analytics\TechChallenge_Fase4\Projeto_Obesidade\FIAP_Tech-Challenge_Fase4\Projeto_Obesidade> python main.py
Valores nulos encontrados: 0
Registros duplicados: 24
Random Forest: 0.9314
SVM: 0.8487
KNN: 0.7920

Melhor modelo: Random Forest
Acurácia: 0.9314

Matriz de Confusão:
[[50  4  0  0  0  0]
 [ 0 53  0  0  0  1]
 [ 0  1 68  0  0  1]
 [ 0  0  1 59  0  0]
 [ 0  1  0  0 64  0]
 [ 0  9  1  0  0 48]
 [ 0  2  2  0  0 25]]

Relatório de Classificação:
      precision    recall  f1-score   support

Insufficient_Weight      1.00      0.93      0.96         54
Normal_Weight            0.76      0.91      0.83         58
Obesity_Type_I           0.94      0.97      0.96         70
Obesity_Type_II          1.00      0.98      0.99         60
Obesity_Type_III         1.00      0.98      0.99         65
Overweight_Level_I       0.89      0.83      0.86         58
Overweight_Level_II      0.96      0.90      0.93         58

   accuracy      0.94      0.93      0.93        423
  macro avg      0.94      0.93      0.93        423
 weighted avg      0.94      0.93      0.93        423

Acurácia Final: 0.9314
Modelo, scaler e colunas salvos com sucesso.

Pipeline finalizado com sucesso.
```

Figura 1: Saída do terminal ao executar o arquivo main.py

3.3. Deploy e Aplicação Preditiva (Streamlit)

Para disponibilizar o modelo em um ambiente acessível à equipe médica, foi desenvolvida uma aplicação utilizando Streamlit.

Principais características da aplicação:

Interface amigável: formulário para inserção dos dados do paciente (gênero, idade, altura, peso, hábitos alimentares, estilo de vida, etc.).

Mapeamento de variáveis: criação de dicionários de tradução para converter respostas em português para o formato esperado pelo modelo.

Pré-processamento automático: aplicação de One-Hot Encoding e normalização dos dados com o scaler salvo na pipeline.


Previsão em tempo real: ao clicar no botão de previsão, o sistema processa os dados e retorna o nível de obesidade previsto.

Resultado traduzido: a saída do modelo é exibida em português, com categorias como Abaixo do peso, Peso normal, Sobrepeso I/II e Obesidade I/II/III.

4. Dashboard Analítico

Foi desenvolvido um painel interativo no **Power BI** utilizando a base original, com o objetivo de fornecer insights relevantes para a equipe médica. O dashboard foi estruturado em quatro tópicos principais:

- **Perfil do Usuário:** análise da distribuição por faixa etária e sexo, além da presença ou ausência de histórico familiar de obesidade.
- **Hábitos de Vida:** avaliação da frequência de atividade física e do tempo de exposição a telas, evidenciando padrões de sedentarismo.
- **Fatores de Risco:** comparação entre diferentes hábitos (alimentação calórica, consumo de álcool, hidratação, sedentarismo) e os níveis de obesidade, destacando os fatores mais associados aos graus mais elevados.
- **Diagnóstico:** distribuição dos indivíduos por nível de obesidade, permitindo visualizar a concentração da população entre sobrepeso e obesidade.



5. Estrutura do Repositório

O projeto foi versionado no GitHub no repositório **FIAP_Tech-Challenge_Fase4**, organizado da seguinte forma:

```
.devcontainer/
├── devcontainer.json      # Configuração do ambiente de desenvolvimento

Projeto_Obesidade/
├── models/               # Artefatos gerados pelo pipeline
│   ├── colunas.pkl       # Lista de colunas utilizadas no treinamento
│   ├── model.pkl         # Modelo de Machine Learning selecionado
│   └── scaler.pkl        # Objeto de normalização (StandardScaler)
├── Analise_Exploratoria_Fase_4.ipynb # Notebook com EDA e tratamento inicial
├── app.py                # Aplicação Streamlit para deploy do modelo
└── main.py               # Pipeline de treinamento e avaliação dos modelos

bases/
├── Obesity.csv           # Base original utilizada no projeto
└── variaveis_obesidade.csv # Dicionário de variáveis

Painel_Control_Obesidade.pbix # Dashboard analítico desenvolvido no Power BI
README.md                    # Documentação inicial do repositório
requirements.txt              # Lista de dependências do projeto
```

6. Entregáveis

- **Repositório GitHub:** contém todo o código, notebooks, pipeline, aplicação e painel analítico. FIAP_Tech-Challenge_Fase4 ([Github.com/LaisST](https://github.com/LaisST))
- **Aplicação Preditiva (Streamlit):** formulário para inserção dos dados do paciente e previsão do nível de obesidade. ([Aplicação Streamlit – Predição de Obesidade](#))
- **Dashboard Analítico (Power BI):** painel interativo com perfil dos usuários, hábitos de vida, fatores de risco e diagnóstico. ([Link de compartilhamento do Power BI](#))

7. Conclusão

Após o desenvolvimento do projeto, pode-se concluir que a base de dados apresentou boa qualidade, sem valores nulos e apenas 24 registros duplicados, que foram mantidos por representarem possíveis pacientes distintos com respostas semelhantes.

Na etapa de modelagem, foram testados diferentes algoritmos de classificação (Random Forest, SVM e KNN). O modelo Random Forest apresentou o melhor desempenho, com acurácia final de 93,14%. Além da alta acurácia, o relatório de classificação evidenciou bom equilíbrio entre precisão nas diferentes classes de obesidade.

O pipeline foi estruturado para garantir reprodutividade, com salvamento dos artefatos principais (`model.pkl`, `scaler.pkl` e `colunas.pkl`), permitindo o uso consistente do modelo em produção. A aplicação desenvolvida em Streamlit possibilita que médicos e médicas insiram dados de pacientes e obtenham previsões em tempo real, enquanto o dashboard analítico em Power BI fornece insights sobre perfil dos usuários, hábitos de vida, fatores de risco e distribuição dos níveis de obesidade (base original).

A análise dos dados evidencia que hábitos pouco saudáveis, como baixa prática de atividade física, consumo frequente de álcool e alimentação calórica, refletem na alta concentração de usuários entre sobrepeso e obesidade. Esses resultados, aliados ao desempenho do modelo preditivo, reforçam a importância de ações preventivas focadas na promoção de hábitos saudáveis e mostram como soluções baseadas em dados podem apoiar a tomada de decisão clínica e estratégias de saúde pública.

